

SPRAWOZDANIE

Zajęcia: Matematyka Konkretna

Prowadzący: prof. dr hab. Vasyl Martsenyuk

Laboratorium Nr 2 Data 31.03.2025 Temat: Metoda SVD w celu obliczenia korelacji Wariant 6	Imię Nazwisko Hubert Mentel Informatyka II stopień, niestacjonarne, 2 semestr, gr.1a
--	---

1. Cel:

Celem jest nabycie podstawowej znajomości użycia rozkładu SVD w celu rozwiązywania problemów powiązanych z użyciem korelacji.

2. Zadania:

Zadanie dotyczy obliczenia korelacji obrazu zgodnie z wariantem pod względem zarówno wierszy jak i kolumn z użyciem SVD. Przedstawić macierzy korelacji graficznie. We wniosku potraktować widoki macierzy korelacji.

Wariant 6:

Obraz w zadaniu 6.webp.

Pliki dostępne są pod linkiem:

<https://github.com/HubiPX/NOD/tree/master/MK/Zadanie%202>

3. Opis programu opracowanego (kody źródłowe, zrzuty ekranu)

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.decomposition import TruncatedSVD
from skimage import io

# Załaduj obraz i znormalizuj
image_url = "6.webp"
image = io.imread(image_url, as_gray=True)
image = image / np.max(image) # Normalizacja do zakresu [0,1]


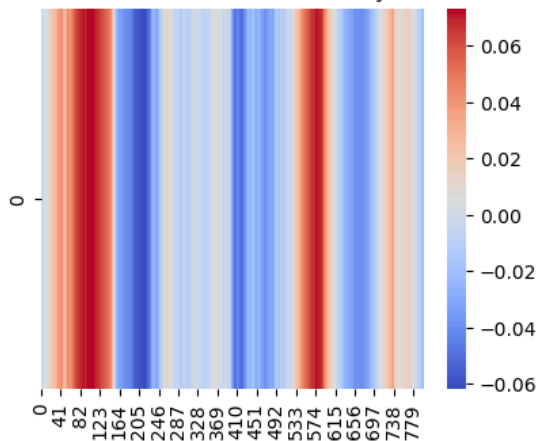
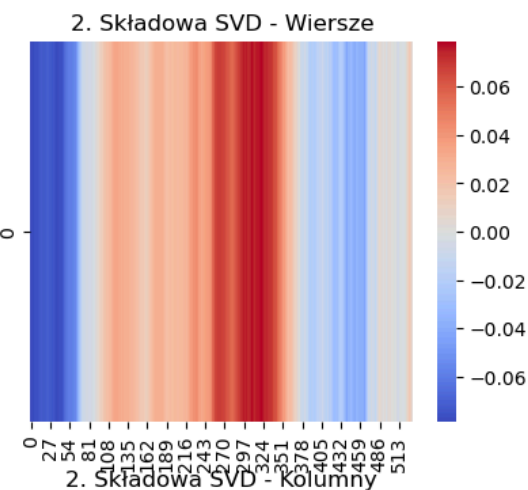
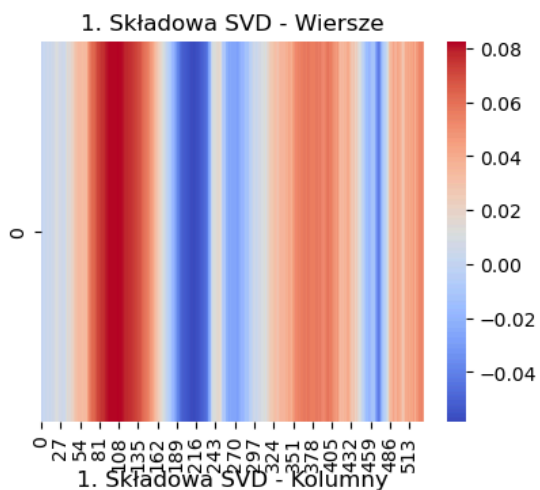



# Macierze korelacji
corr_matrix_rows = np.corrcoef(image)
corr_matrix_cols = np.corrcoef(image.T)

# Rozkład SVD
svd_rows = TruncatedSVD(n_components=5)
svd_cols = TruncatedSVD(n_components=5)
svd_rows.fit(corr_matrix_rows)
svd_cols.fit(corr_matrix_cols)

# Wizualizacja macierzy korelacji
fig, ax = plt.subplots(1, 2, figsize=(12, 5))
sns.heatmap(corr_matrix_rows, ax=ax[0], cmap="coolwarm", cbar=True)
ax[0].set_title("Macierz Korelacji - Wiersze")
sns.heatmap(corr_matrix_cols, ax=ax[1], cmap="coolwarm", cbar=True)
ax[1].set_title("Macierz Korelacji - Kolumny")
plt.show()

# Wizualizacja wartości osobliwych
plt.figure(figsize=(6, 4))
plt.plot(range(1, 6), svd_rows.singular_values_, marker='o', label="Wiersze")
plt.plot(range(1, 6), svd_cols.singular_values_, marker='s', label="Kolumny")
plt.xlabel("Indeks składowej")
plt.ylabel("Wartość osobliwa")
plt.legend()
plt.title("Wartości osobliwe (SVD)")
plt.show()

# Wizualizacja pierwszych dwóch składowych
fig, ax = plt.subplots(2, 2, figsize=(10, 8))
sns.heatmap(svd_rows.components_[0].reshape(1, -1), ax=ax[0, 0], cmap="coolwarm", cbar=True)
ax[0, 0].set_title("1. Składowa SVD - Wiersze")
sns.heatmap(svd_rows.components_[1].reshape(1, -1), ax=ax[0, 1], cmap="coolwarm", cbar=True)
ax[0, 1].set_title("2. Składowa SVD - Wiersze")
sns.heatmap(svd_cols.components_[0].reshape(1, -1), ax=ax[1, 0], cmap="coolwarm", cbar=True)
ax[1, 0].set_title("1. Składowa SVD - Kolumny")
sns.heatmap(svd_cols.components_[1].reshape(1, -1), ax=ax[1, 1], cmap="coolwarm", cbar=True)
ax[1, 1].set_title("2. Składowa SVD - Kolumny")
plt.show()
```



4. Wnioski

W ramach tego zadania przeprowadziliśmy analizę obrazu przy użyciu dekompozycji wartości osobliwych (SVD) oraz macierzy korelacji. Obliczyliśmy macierze korelacji dla wierszy i kolumn obrazu, a następnie dokonaliśmy ich dekompozycji SVD. Dzięki temu mogliśmy zobaczyć, jak różne składowe obrazu są ze sobą powiązane i jakie informacje są najistotniejsze.

Analiza wartości osobliwych pokazała, że największa część informacji zawarta jest w kilku pierwszych składowych SVD. Oznacza to, że obraz można skutecznie zredukować do mniejszej liczby wymiarów bez dużej utraty jakości. Wizualizacja pierwszych składowych potwierdza, że główne cechy obrazu można uchwycić już przy kilku dominujących składowych, co jest zgodne z teorią dotyczącą SVD.

Zastosowanie macierzy korelacji pozwoliło również zobaczyć, jak intensywność pikseli zmienia się wzdłuż wierszy i kolumn. Obserwujemy, że pewne obszary obrazu są silniej skorelowane, co może wskazywać na obecność struktur takich jak krawędzie czy powtarzające się wzory. Może to mieć praktyczne zastosowania w analizie obrazów, np. w kompresji danych czy filtracji szumów.