SPRAWOZDANIE

Zajęcia: Nauka o danych I

Prowadzący: prof. dr hab. Vasyl Martsenyuk

Laboratorium Nr 5 Data 09.01.2025 Temat: Wykorzystanie narzędzi do eksploracyjnej analizy danych (EDA)	Imię Nazwisko Hubert Mentel Informatyka II stopień, niestacjonarne, 1 semestr, gr.1a

1. Zadanie:

Proszę na podstawie własnego zbioru danych poprowadzić zaawansowaną eksploracyjną analizę danych, w tym:

- identyfikować wartości odstające za pomocą algorytmu Isolation Forest,

- redukować wymiarowość danych z użyciem PCA,

- tworzyć zaawansowane interaktywne wizualizacje danych,

- wizualizować dane wielowymiarowe za pomocą zaawansowanych algorytmów (t-SNE, UMAP),

- tworzyć interaktywne wizualizacje danych w 2D i 3D,

- analizować zależności między zmiennymi za pomocą macierzy korelacji.

- przeprowadzać testy statystyczne dla analizy różnic w grupach.

Pliki dostępne są na GitHubie pod linkiem:
https://github.com/HubiPX/NOD/tree/master/Zadanie%205

2. Opis programu opracowanego (kody źródłowe, zrzuty ekranu)

[1]:
```
import pandas as pd
import seaborn as sns
import plotly.express as px
import plotly.graph_objects as go
import matplotlib.pyplot as plt
import numpy as np
from sklearn.ensemble import IsolationForest
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

# Wczytanie pliku CSV
file_path = "gpu_data.csv"  # Upewnij się, że plik jest w tym samym katalogu co skrypt
data = pd.read_csv(file_path)

# Zmiana ustawień wyświetlania, aby pokazać wszystkie wiersze
pd.set_option('display.max_rows', None)

# Wyświetlenie wszystkich wierszy
print(data)
```

```
                Model  Technology (nm)  Die Size (mm²)  ROP Units  TMU Units  \
0         GTX 750 Ti               28             148         16         40
1            GTX 760               28             294         32         96
2            GTX 770               28             294         32        128
3            GTX 780               28             561         48        192
4         GTX 780 Ti               28             561         48        240
5            GTX 960               28             228         32         64
6            GTX 970               28             398         56        104
7            GTX 980               28             398         64        128
8         GTX 980 Ti               28             601         96        176
9        GTX 1050 Ti               14             132         32         48
10          GTX 1060               16             200         48         80
11          GTX 1070               16             314         64        120
12       GTX 1070 Ti               16             314         64        152
13          GTX 1080               16             314         64        160
14       GTX 1080 Ti               16             471         88        224
15          RTX 2060               12             445         48        120
16    RTX 2060 Super               12             445         64        136
```

[3]:
```
# 1. Zidentyfikować wartości odstające za pomocą algorytmu Isolation Forest
df = pd.read_csv("gpu_data.csv")

# Wybierz tylko kolumny liczbowe do analizy
numerical_df = df.select_dtypes(include=['float64', 'int64'])

# Przeskalowanie danych
scaler = StandardScaler()
numerical_df_scaled = scaler.fit_transform(numerical_df)

# Model Isolation Forest
iso_forest = IsolationForest(contamination=0.05, random_state=42)
outliers = iso_forest.fit_predict(numerical_df_scaled)

# Oznaczenie wartości odstających (-1 oznacza odstające, 1 oznacza normalne)
df['Wartości odstające'] = np.where(outliers == -1, 'Odstające', 'Normal')

df.to_csv("gpu_data_with_outliers.csv", index=False)

# Wizualizacja rozkładu wartości odstających
plt.figure(figsize=(10, 6))
sns.countplot(data=df, x='Wartości odstające')
plt.title("Rozkład wartości odstających dla danych GPU")
plt.show()

# Wizualizacja zmiennych z uwzględnieniem wartości odstających
plt.figure(figsize=(12, 8))
sns.boxplot(data=df, x='Wartości odstające', y='TDP (W)')
plt.title("TDP w podziale na wartości odstające")
plt.show()
```

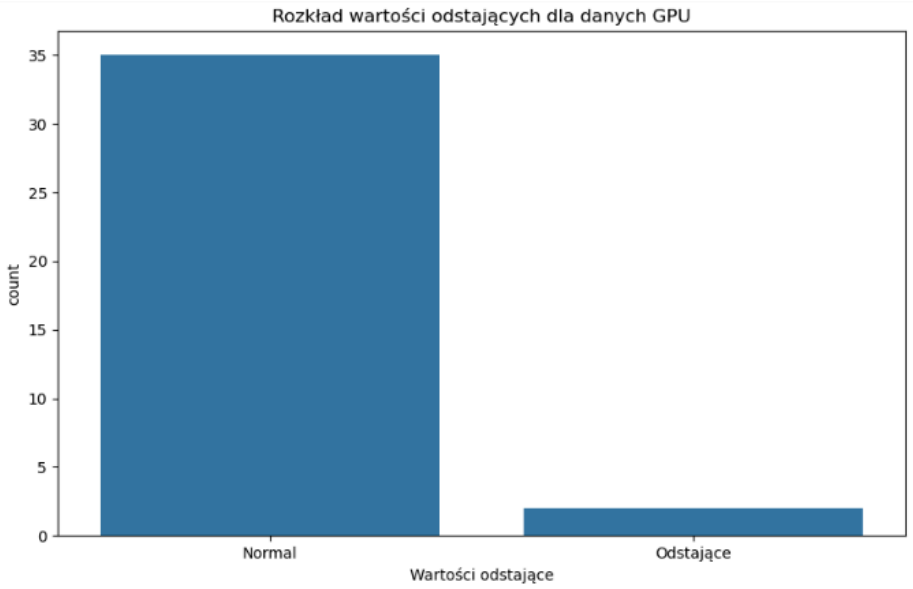
Rozkład wartości odstających dla danych GPU
count
0
5
10
15
20
25
30
35
Normal
Odstające
Wartości odstające

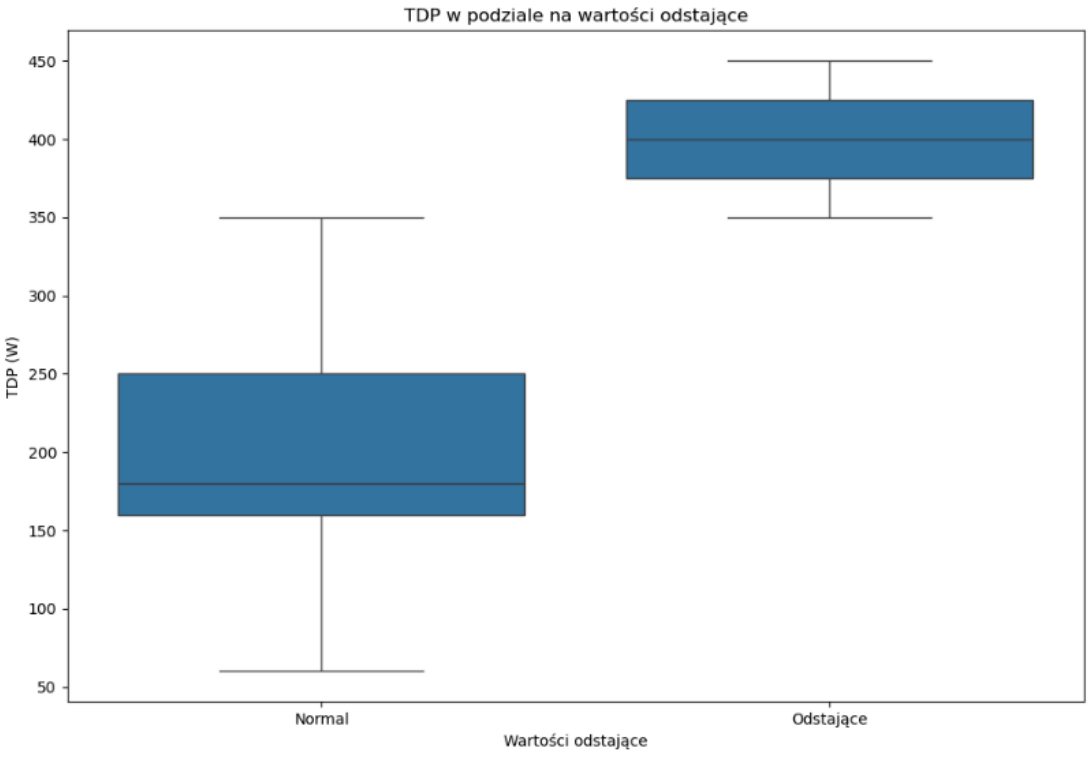
TDP w podziale na wartości odstające
TDP (W)
50
100
150
200
250
300
350
400
450
Normal
Odstające
Wartości odstające

[5]:
```
# 2. Redukować wymiarowość danych z użyciem PCA,

numerical_df = df.select_dtypes(include=['float64', 'int64'])

scaler = StandardScaler()
numerical_df_scaled = scaler.fit_transform(numerical_df)

pca = PCA(n_components=2)
pca_result = pca.fit_transform(numerical_df_scaled)

df['PC1'] = pca_result[:, 0]
df['PC2'] = pca_result[:, 1]

pca_df = pd.DataFrame(pca_result, columns=['PC1', 'PC2'])

explained_variance = pca.explained_variance_ratio_
print(f"Wariancja wyjaśniana przez każdą składową: {explained_variance}")
print(f"Łączna wariancja: {sum(explained_variance):.2f}")

plt.figure(figsize=(8, 6))
plt.scatter(pca_df['PC1'], pca_df['PC2'], alpha=0.7)
plt.xlabel('PC1')
plt.ylabel('PC2')
plt.title('Wizualizacja danych GPU po PCA')
plt.show()
```

```
Wariancja wyjaśniana przez każdą składową: [0.6000948  0.24329501]
Łączna wariancja: 0.84
```

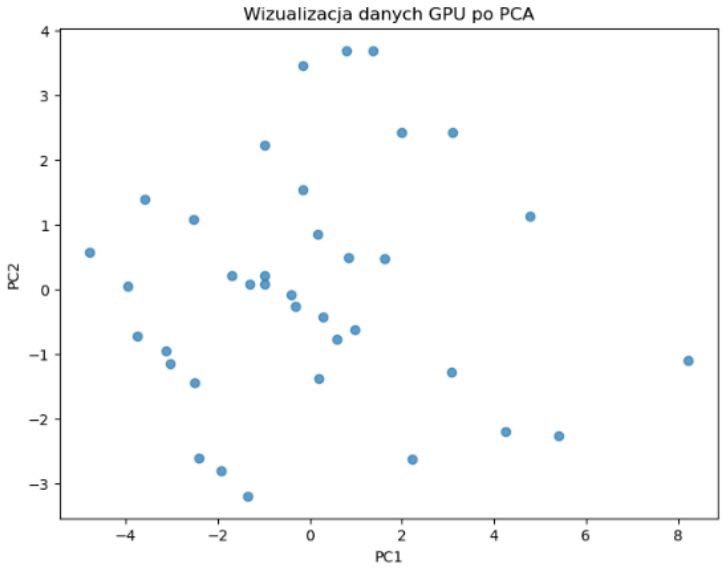

[7]:
```
# 3. Tworzyć zaawansowane interaktywne wizualizacje danych,
df['Różnica między Base a Boost Clock'] = df['Base Clock (MHz)'] - df['Boost Clock (MHz)']

# Tworzenie wykresu rozrzutu z interaktywnymi danymi
fig_pca = px.scatter(df,
                     x='Różnica między Base a Boost Clock',
                     y='CUDA Cores',
                     color='Memory Size (GB)',
                     hover_data=['Model', 'Base Clock (MHz)', 'Boost Clock (MHz)', 'CUDA Cores', 'Memory Size (GB)', 'TDP (W)'],
                     title='Zależność między różnicą Base/Boost Clock a ilością rdzeni CUDA',
                     labels={'Różnica między Base a Boost Clock': 'Różnica Base/Boost Clock (MHz)',
                             'CUDA Cores': 'Liczba rdzeni CUDA',
                             'Memory Size (GB)': 'Pamięć (GB)'})
fig_pca.show()
```

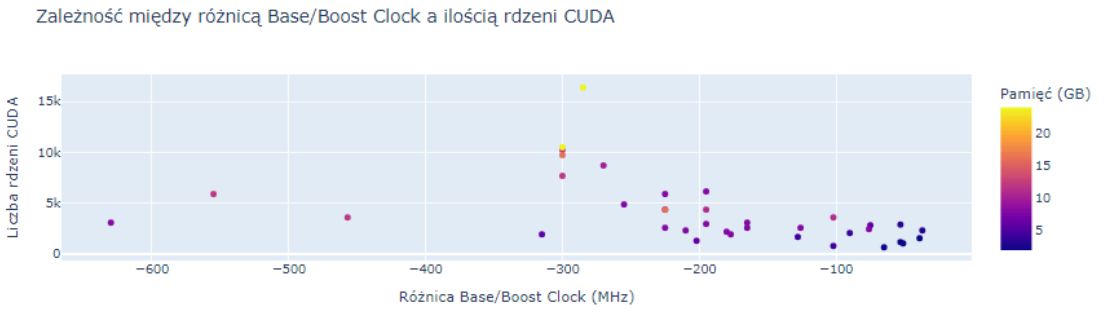

[9]:
```
fig_box = px.box(df,
                 x='Wartości odstające',
                 y='TDP (W)',  # Możemy analizować np. TDP (W) lub inną interesującą zmienną
                 color='Wartości odstające',
                 title='Rozkład TDP w zależności od wartości odstających',
                 labels={'TDP (W)': 'Zużycie energii (W)', 'Wartości odstające': 'Typ wartości odstających'})
fig_box.show()
```

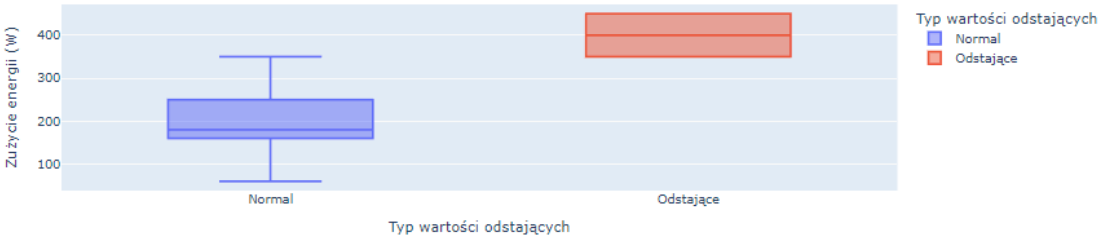

[11]:
```
fig_hist = px.histogram(df,
                        x='Wartości odstające',
                        color='Wartości odstające',
                        title='Rozkład wartości odstających w danych GPU',
                        marginal='box')  # Dodanie wykresu pudełkowego na marginesie

fig_hist.show()
```

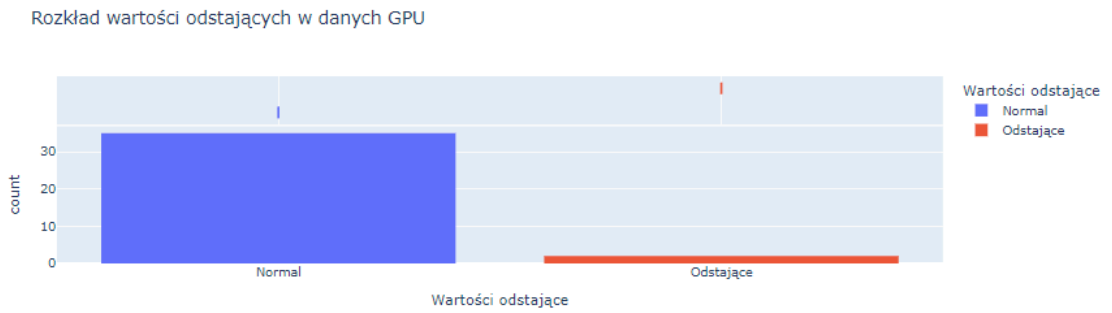

[13]:
```
fig_children_income = px.scatter(df,
                                 x='ROP Units',
                                 y='Price (USD)',
                                 color='Price (USD)',
                                 hover_data=['Model', 'ROP Units', 'Price (USD)', 'TDP (W)', 'Memory Size (GB)'],
                                 title='Zależność między liczbą jednostek ROP a ceną karty graficznej')

fig_children_income.show()
```

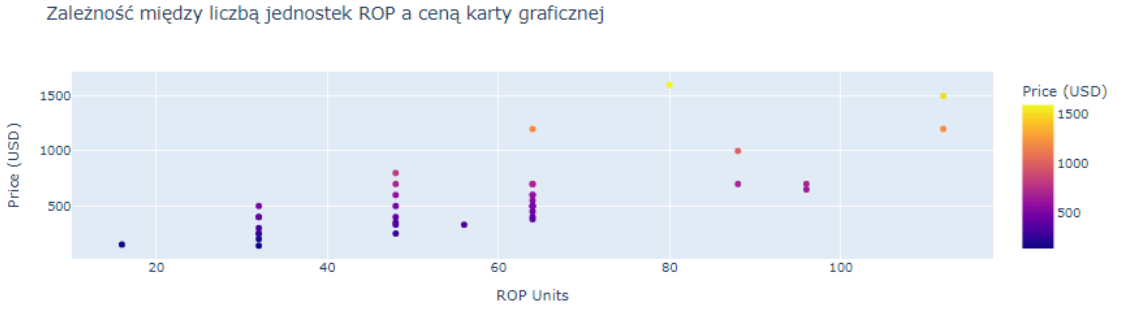

[15]:
```
# 4. Zwizualizować dane wielowymiarowe za pomocą zaawansowanych algorytmów (t-SNE, UMAP)
!pip install umap-learn
from sklearn.manifold import TSNE
from umap import UMAP


# Wybór interesujących kolumn
columns_of_interest = ['TDP (W)', 'Price (USD)', 'CUDA Cores', 'Memory Size (GB)', 'Base Clock (MHz)', 'Boost Clock (MHz)']
X = df[columns_of_interest]

# Przeskalowanie danych
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Użycie UMAP do redukcji wymiarowości
umap_model = UMAP(n_components=2, random_state=42)
umap_results = umap_model.fit_transform(X_scaled)

# Użycie t-SNE do redukcji wymiarowości
tsne_model = TSNE(n_components=2, random_state=42, perplexity=30, n_iter=300)
tsne_results = tsne_model.fit_transform(X_scaled)

# Przekształcenie wyników do DataFrame
umap_df = pd.DataFrame(umap_results, columns=['UMAP1', 'UMAP2'])
tsne_df = pd.DataFrame(tsne_results, columns=['t-SNE1', 't-SNE2'])

# Dodanie wyników do oryginalnego DataFrame
df_umap = pd.concat([df, umap_df], axis=1)
df_tsne = pd.concat([df, tsne_df], axis=1)

# Wizualizacja UMAP
plt.figure(figsize=(10, 8))
sns.scatterplot(data=df_umap, x='UMAP1', y='UMAP2', hue='Price (USD)', palette='viridis', s=100, alpha=0.8)
plt.title('UMAP Visualization of GPU Data')
plt.show()

# Wizualizacja t-SNE
plt.figure(figsize=(10, 8))
sns.scatterplot(data=df_tsne, x='t-SNE1', y='t-SNE2', hue='Price (USD)', palette='viridis', s=100, alpha=0.8)
plt.title('t-SNE Visualization of GPU Data')
plt.show()
```

```
Requirement already satisfied: umap-learn in c:\hubert\programy\anaconda\lib\site-packages (0.5.7)
Requirement already satisfied: numpy>=1.17 in c:\hubert\programy\anaconda\lib\site-packages (from umap-learn) (1.26.4)
Requirement already satisfied: scipy>=1.3.1 in c:\hubert\programy\anaconda\lib\site-packages (from umap-learn) (1.13.1)
Requirement already satisfied: scikit-learn>=0.22 in c:\hubert\programy\anaconda\lib\site-packages (from umap-learn) (1.4.2)
Requirement already satisfied: numba>=0.51.2 in c:\hubert\programy\anaconda\lib\site-packages (from umap-learn) (0.59.1)
Requirement already satisfied: pynndescent>=0.5 in c:\hubert\programy\anaconda\lib\site-packages (from umap-learn) (0.5.13)
Requirement already satisfied: tqdm in c:\hubert\programy\anaconda\lib\site-packages (from umap-learn) (4.66.4)
Requirement already satisfied: llvmlite<0.43,>=0.42.0dev0 in c:\hubert\programy\anaconda\lib\site-packages (from numba>=0.51.2->umap-learn) (0.42.0)
Requirement already satisfied: joblib>=0.11 in c:\hubert\programy\anaconda\lib\site-packages (from pynndescent>=0.5->umap-learn) (1.4.2)
Requirement already satisfied: threadpoolctl>=2.0.0 in c:\hubert\programy\anaconda\lib\site-packages (from scikit-learn>=0.22->umap-learn) (2.2.0)
Requirement already satisfied: colorama in c:\hubert\programy\anaconda\lib\site-packages (from tqdm->umap-learn) (0.4.6)
```

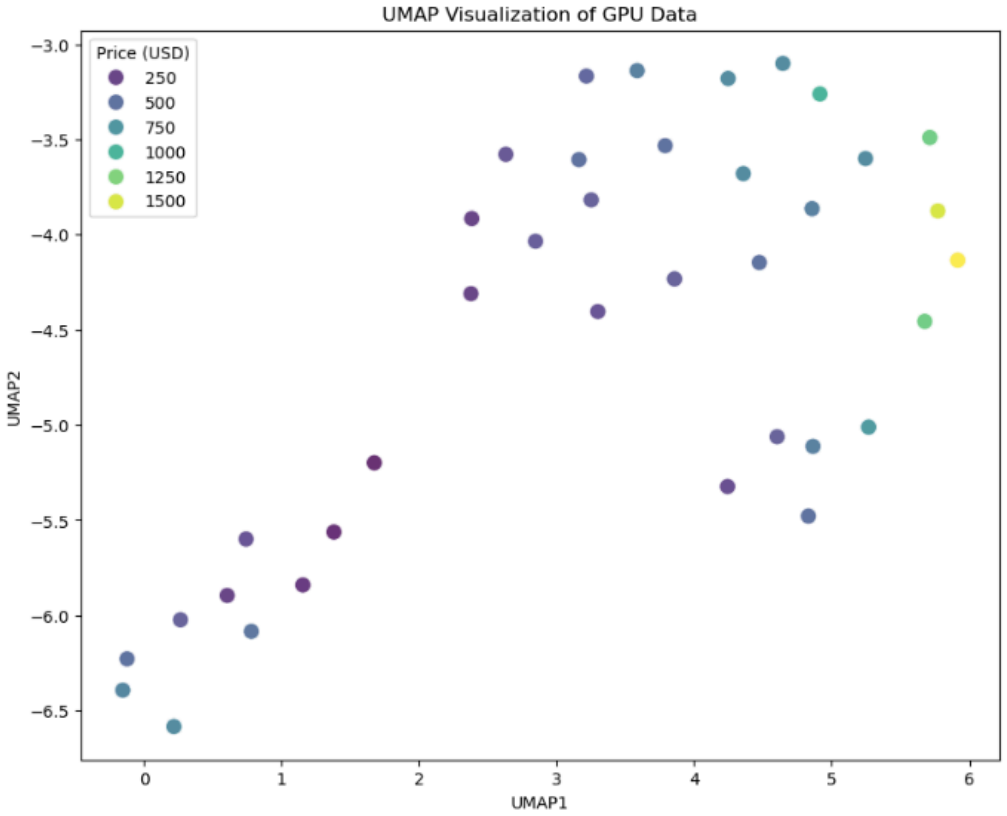
UMAP Visualization of GPU Data
Price (USD)
250
500
750
1000
1250
1500
UMAP2
UMAP1
−3.0
−3.5
−4.0
−4.5
−5.0
−5.5
−6.0
−6.5
0
1
2
3
4
5
6

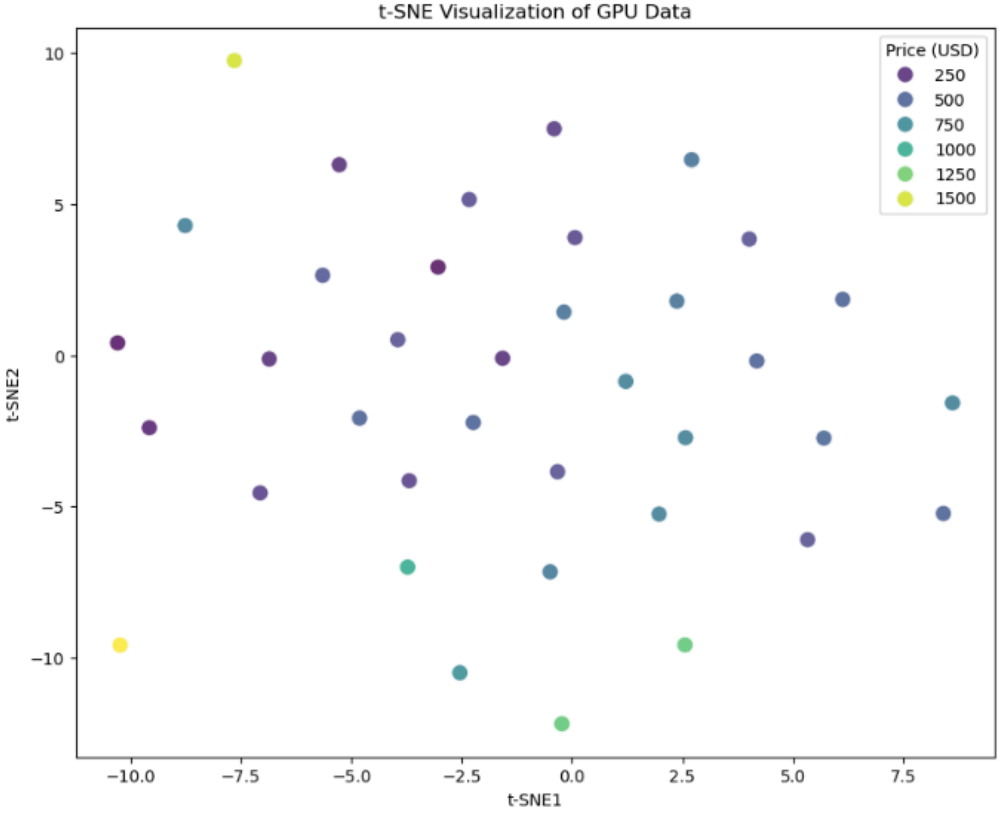
t-SNE Visualization of GPU Data
Price (USD)
250
500
750
1000
1250
1500
t-SNE2
t-SNE1
10
5
0
−5
−10
−10.0
−7.5
−5.0
−2.5
0.0
2.5
5.0
7.5

[16]:
```
# 5. tworzyć interaktywne wizualizacje danych w 2D i 3D,
# Wykres 2D: Cena vs CUDA Cores
fig = px.scatter(df, x='CUDA Cores', y='Price (USD)', color='Model',
                 hover_data=['Model', 'Price (USD)', 'CUDA Cores'])
fig.update_layout(title="Cena vs Liczba rdzeni CUDA",
                  xaxis_title="Liczba rdzeni CUDA",
                  yaxis_title="Cena (USD)")
fig.show()
fig = px.scatter_3d(df, x='CUDA Cores', y='Base Clock (MHz)', z='Price (USD)',
                    color='Model', hover_data=['Model', 'CUDA Cores', 'Base Clock (MHz)', 'Price (USD)'])
fig.update_layout(title="Zależność między Liczbą rdzeni CUDA, Base Clock i Ceną")
fig.show()
```

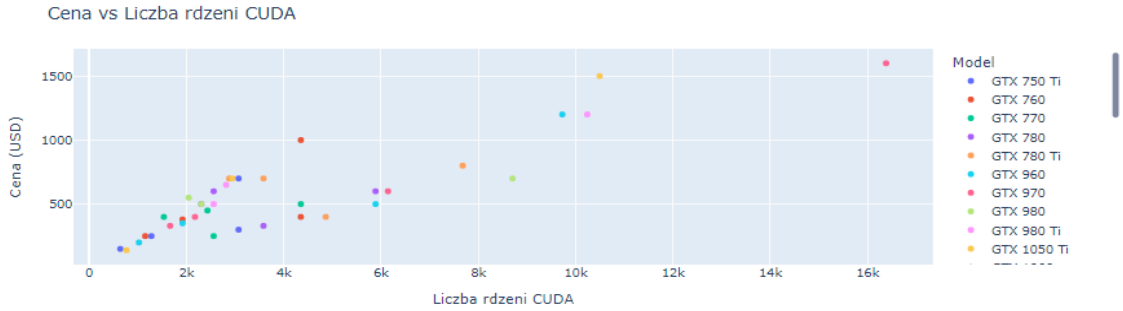

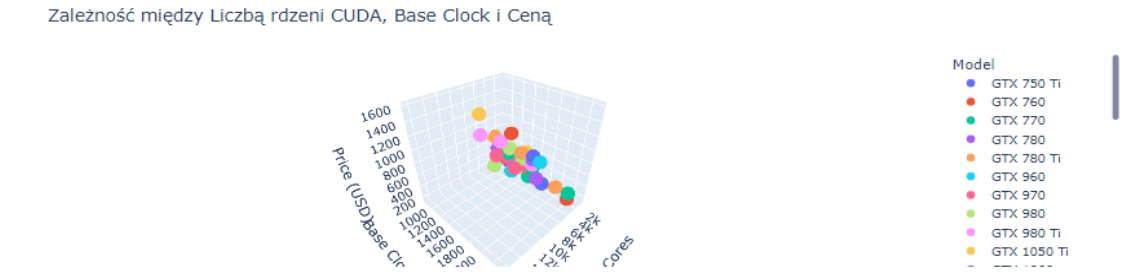

[18]:
```
# 6. Analizować zależności między zmiennymi za pomocą macierzy korelacji.
import plotly.figure_factory as ff

numerical_features = [
    'Technology (nm)', 'Die Size (mm²)','CUDA Cores'
]
numeric_df = df[numerical_features]

# Tworzenie macierzy korelacji
correlation_matrix = numeric_df.corr()

# Wizualizacja macierzy korelacji za pomocą heatmapy
fig = ff.create_annotated_heatmap(
    z=correlation_matrix.values,
    x=correlation_matrix.columns.tolist(),
    y=correlation_matrix.columns.tolist(),
    colorscale='Viridis',
    showscale=True,
)

# Aktualizacja tytułu wykresu
fig.update_layout(title="Macierz korelacji zmiennych GPU")

# Wyświetlenie wykresu
fig.show()
```

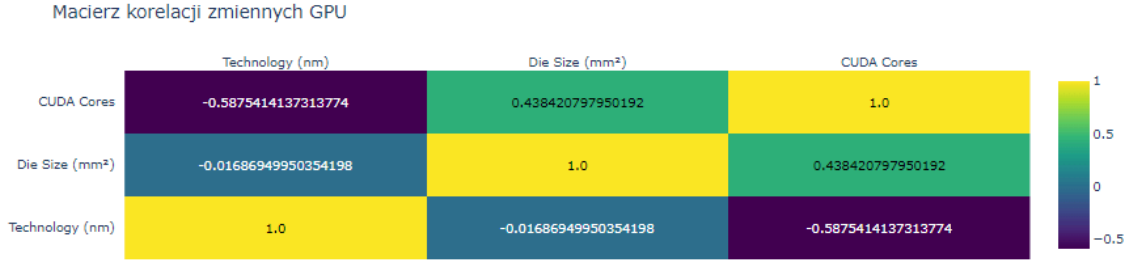

[21]:
```python
# 7. Przeprowadzać testy statystyczne dla analizy różnic w grupach.
from scipy import stats

# Tworzenie grup "GTX" i "RTX" na podstawie nazwy modelu
gtx_group = df[df['Model'].str.contains('GTX')]['Price (USD)']
rtx_group = df[df['Model'].str.contains('RTX')]['Price (USD)']

# Test T-studenta dla różnic w cenie
t_stat, p_value = stats.ttest_ind(gtx_group, rtx_group)

print(f"T-statystyka: {t_stat}")
print(f"P-wartość: {p_value}")
if p_value < 0.05:
    print("Istnieje istotna różnica w średnich cenach między kartami GTX a RTX.")
else:
    print("Brak istotnej różnicy w średnich cenach między kartami GTX a RTX.")
```

```
T-statystyka: -2.464907742937319
P-wartość: 0.018756532759691073
Istnieje istotna różnica w średnich cenach między kartami GTX a RTX.
```

[23]:
```python
from statsmodels.formula.api import ols
from statsmodels.stats.anova import anova_lm

# Utworzenie nowej kolumny 'Technology' dla GTX/RTX
df['Technology'] = df['Model'].apply(lambda x: 'GTX' if 'GTX' in x else 'RTX')


df.rename(columns={'Price (USD)': 'Price'}, inplace=True)
# Model ANOVA dla analizy ceny w zależności od technologii (GTX vs RTX)
model = ols('Price ~ C(Technology)', data=df).fit()
anova_table = anova_lm(model)

print(anova_table)

if anova_table['PR(>F)'].iloc[0] < 0.05:
    print("Istnieje istotna różnica w średnich cenach między kartami GTX a RTX.")
else:
    print("Brak istotnej różnicy w średnich cenach między kartami GTX a RTX.")
```

```
                df        sum_sq        mean_sq        F    PR(>F)
C(Technology)   1.0  6.335137e+05  633513.718264  6.07577  0.018757
Residual       35.0  3.649411e+06  104268.874459      NaN       NaN
Istnieje istotna różnica w średnich cenach między kartami GTX a RTX.
```

3. Wnioski

W wyniku przeprowadzonej analizy dostrzegłem możliwość wykrywania wartości odstających za pomocą algorytmu Isolation Forest, co pozwala na skuteczne identyfikowanie anomalii w danych. Redukcja wymiarowości przy użyciu PCA oraz zaawansowane techniki wizualizacji, takie jak t-SNE i UMAP, umożliwiły lepsze zrozumienie struktur danych wielowymiarowych. Dodatkowo, przeprowadzenie testów statystycznych, w tym ANOVA, pozwoliło na ocenę istotności różnic między grupami oraz głębsze zrozumienie zależności między zmiennymi.